TRABAJO PRÁCTICO INTEGRADOR · DEL PROBLEMA AL DEPLOY



Asistente de Mesa de Ayuda WMS

Gestión y derivación automática de dudas operativas

Autor: Ignacio Toto

1. El Problema de Negocio: Migración de Sistema WMS

Transición de 20 Años

Migración de un WMS desarrollado in-house hace 20 años hacia un software estándar de mercado. Cambio de pantallas, teclas y flujos de trabajo.

Saturación de Key Users

Durante el Go-Live, los referentes operativos y líderes de proyecto quedan saturados respondiendo preguntas básicas repetitivas, paralizando su foco en incidencias críticas.

Dispersión y Demoras

Los operarios envían la misma consulta por múltiples canales (WhatsApp, Teams, radio), generando sobrecarga, retardos y descoordinación.

2. El Modelo Elegido: BERT o SELECTRA

Criterio	BERT-XNLI (110M)	SELECTRA-Medium (38M)	Impacto Operativo
Tamaño de los pesos	~440 MB	~163 MB	63% más liviano
Tiempo de carga en memoria	5.77 s - 6.15 s	0.64 s - 0.72 s	8x a 9x más rápido en el arranque
Latencia media por inferencia	~0.40 s - 0.42 s	~0.13 s - 0.18 s	3x más veloz en tiempo real
Consumo de memoria RAM	~600 MB - 800 MB	< 300 MB	Apto Free Tier (1 GB)
Decisión para el Deploy	Descartado	**SELECCIONADO**	Ligereza, estabilidad y fluidez

Conclusión del Benchmark:
Las pruebas realizadas demostraron precisión similar entre ambos proyecto, pero SELECTRA-Medium ofrece una ventaja importante en eficiencia de hardware: consume la mitad de RAM y es mucho más veloz. Estas condiciones lo posiciona mejor considerando los recursos necesarios al momento de implementar.

3. Dónde vive el código y Donde vive el Modelo

El código está almacenado en un repositorio en **GitHub**, lo cual ofrece las siguientes ventajas:

- Control de Versionado
- Trabajo en equipo
- Alojamiento en la nube y respaldo
- Integración continua y automatización



El modelo está ubicado en **Hugging Face**. Pero debido a que se utiliza **Pipeline** en lugar de **InferenceClient**, al momento de la ejecución los pesos del modelo se descargan en el contenedor de **Streamlit**. De esta forma se evitan las limitaciones impuestas por **Hugging Face**.





4. El Deploy



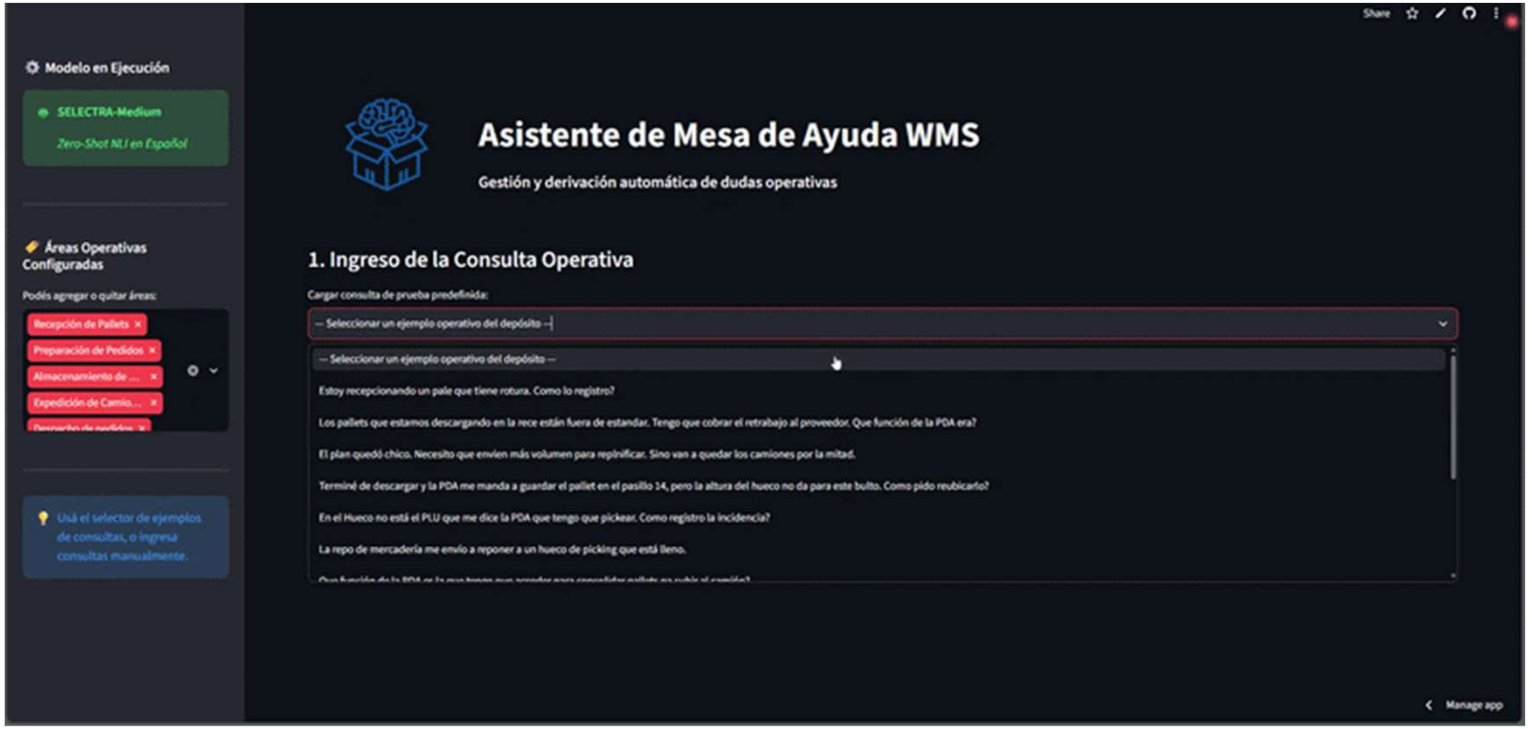
Streamlit

- Alojamiento gratuito
- Integración con GitHub
- Despliegue con un clic
- Dominio personalizado
- Spin down de 12 horas
- 1 GB de RAM y 1 CPU por contenedor
- Solo para aplicaciones Python con Streamlit

Render

- Alojamiento gratuito
- Integración con GitHub
- Despliegue requiere configuración
- Spin down de 15 minutos
- 512 MB de RAM y 1 CPU por contenedor
- Solo para aplicaciones Python con Streamlit
- Permite Streamlit, FastAPI, Node.js, etc.

5. La App

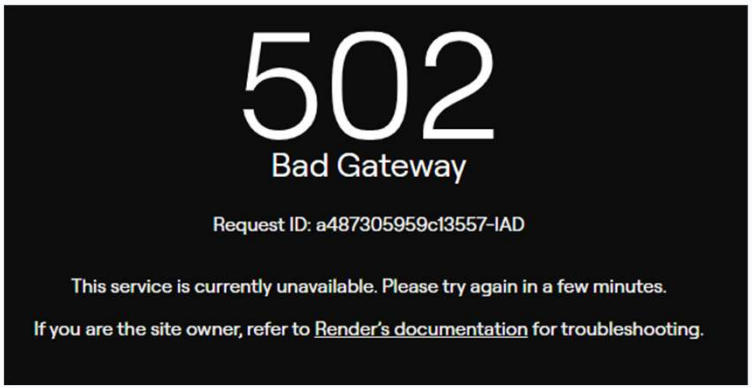


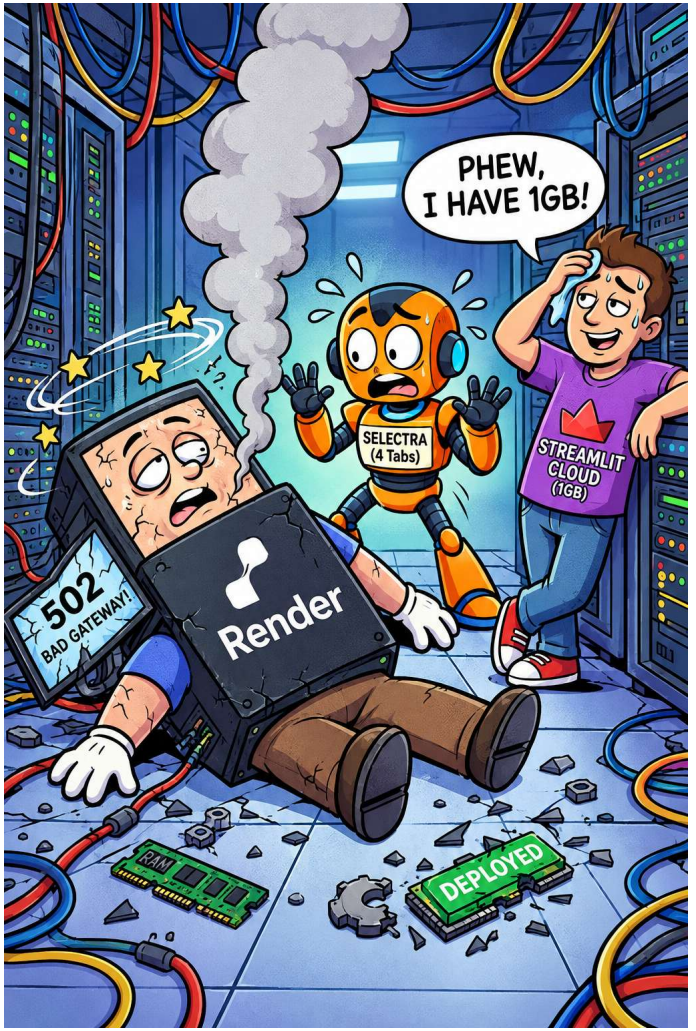
https://seminario.streamlit.app/

6. Un error…que pudo haber ocurrido

El aprendizaje es:
“No quedarse con lo que ocupan los pesos”

Con los 512MB de Render, los 163MB de SELECTRA parecen suficientes. Sin embargo, es importante considerar la cantidad de parámetros, y las librerías necesarias para que todo funcione.





7. Límites y Próximos Pasos

Límites

• Si bien Streamlit Cloud ofrece recursos suficientes para este proyecto, exigirlo con múltiples usuarios en paralelo probablemente lleve el deploy al límite y falle.

• Las herramientas gratuitas implican asumir el riesgo de que de un momento a otro cambien las condiciones del servicio y que el proyecto ya no sea viables sin mudarse a servicios de pago.

• La selección del modelo SELECTRA estuvo asociado al límite de 1GB RAM que ofrece Streamlit. Con menos recursos hubiera migrado al modelo small, sacrificando, probablemente, algo de precisión en las respuestas.

Próximos Pasos

• Llevar esta App a un entorno productivo, implicaría modificar el diseño/arquitectura de la aplicación que soporte múltiples usuarios al mismo tiempo.

• Utilizar infraestructura más sólida, con más recursos y escalabilidad.

• Evaluar la disponibilidad de dataset con datos históricos de consultas de los usuarios, etiquetarlos y usarlos para entrenar un modelo supervisado, a fin de lograr mejor precisión en las respuestas



Gracias